




Image-Fusion and Breast Lesion Analysis for a later AR application to improve surgery outcomes

BY NADAV EPSTEIN & OR TRABELSI

WITH THE MENTORING OF DR ASAF HOGI

מה המטרה?

- ▶ המטרה שלנו היא לשפר את הסגמנטציה של גידול בשד באמצעות רשת נוירונים עמוקה המבוססת על מחקרו של ד"ר אסף חוגי ושות'. אנחנו, בשיתוף פעולה עם בית החולים תל השומר, בונים מערכת זיהוי אוטומטית לחלוטין אשר בהינתן תמונת MRI/Mammography תוכל לסמן לנו בדיוק רב היכן נימצא הגידול.
- ▶ עוד תוכנן לפתח מערכת AR אשר תוכל לזהות את הגידול ישירות מגוף המטופל ולהציג אותו באייפד לנוחות הרופא.



הבסיס לפרוייקט

▶ סרטן השד הוא הסרטן הנפוץ ביותר בקרב נשים ברחבי העולם. לצערנו ישנם מקרים רבים אשר המנתח מוציא רק חלק מהגידול או אפילו מוציא קצת יותר מדי, לכן מערכת אשר מסמנת בדיוק רב את הגידול תוכל לחסוך מנשים לעבור את הניתוח בשנית לאחר שהראשון לא צלח. בנוסף מערכת זו תחסוך זמן רב לרופאים ותייעל את המערכת כולה בעקבות זאת.



שיטת פעולה

► קבלת מידע ממספר מקורות שונים (MRI/MAMOGRAPHY...) לאחר מכן נבצע סגמנטציה וזיהוי של הגידול (analysis lesion) (fusion) כלל מקורות המידע כדי להגיע לתוצאות טובות יותר.

► השתמשנו ברשת מוכרת לסגמנטציה אשר נקראת UNET ובשילוב של רשת זו ביחד עם Level-Set (שיטה אשר עוזרת לסגמנטציה) ובעזרת שילוב שיטות אלו נוכל להגיע לתוצאות טובות יותר!

► הlevel-set בוחר לעצמו על ידי אימון פרמטרים אשר ימקסמו את הסגמנטציה.

► בנוסף כתוכנית להמשך נרצה לזהות את מנה המטופל בעזרת חיישנים נוספים ובכך לשפר עוד יותר את הדיוק.





Figure 1. Illustrations of the level set method and the contour change

skip connections

על מנת לבצע סגמיטציה אנו משתמשים בשיטת skip connections, מה זה אומר?
ככל שאנו נכנסים יותר לעומק ברשת CNN אנו נתעסק בפ'יצרים יותר "מסובכים" ועל מנת לבצע סגמיטציה אנו נצטרך גם את הפיצ'רים הללו וגם את הפשוטים יותר לכן אחרי כל שכבת CNN אנחנו נשמור את ה- output שלה וכאשר נעשה DeConv אנו נחבר כל שכבה בגודל המתאים עם השכבה המתאימה לה ובכך אנו נוכל לנצל את שני סוגי הפיצ'רים שחילצנו ולבצע סגמיטציה בצורה טובה.




Unet

ארכיטקטורת CNN זו מעוצבת בצורת U. הרשת הזו הוכיחה את עצמה בהרבה פרויקטים של זיהוי וסגמנטציית תמונה. היתרון העיקרי של ארכיטקטורה זו הוא שאנו לא צריך הרבה דאטה כדי לאמן את המודל. רשת זו יכולה להיות מיוצגת על ידי שני שלבים עיקריים הצד השמאלי של צורת U (למטה) והצד הימני (למעלה).

הצד הראשון (down stream) אחראי על הוצאת הפיצ'רים המרכזיים והורדת הרזולוציה (encoder) הצד השני (up-stream) מקבל שני קלטים, האחד הוא הפלט של הצד הראשון והשני הינו הפלט של השכבה הקודמת של ה up-stream).

ה down stream מקבל כקלט את התמונה ומבצע עליה שלוש שכבות של קונבולוציה ולאחר מכן max-pooling תהליך זה מתבצע 4 פעמים כאשר כל פעם הפלט של כל שכבה נשמר כדי לבצע concat ב up stream ולהגיע בחזרה לגודל המקורי של הקלט.



פונקציות

- ▶ פונקציית הloss שלנו הינה - `bcewithlogitslos` שהיא בעצם פונקציית `cross entropy` הרגילה עם הוספה של שכבת `sigmoid`.
- ▶ האופטימיזר שבחרנו הינו – `Adam optimizer` שהינו שילוב של שני מנגנוני אופטימיזציה שונים (`momentum & sgd`).
- ▶ את הייפר פרמטרים בחרנו על ידי ניסויים.

מדד דיוק המודל


► כדי למדוד כמה המודל שלנו מדויק השתמשנו בdice score, אשר בשונה מaccuracy יגיד לנו בדיוק כמה הסגמנטציה שלנו נכונה ולא רק כמה פיקסלים שחורים מתאימים לשחורים וכמה פיקסלים לבנים מתאימים ללבנים לדוגמא אם יש לנו target שהוא תמונה שחורה עם גידול קטן מסומן בלבן אנחנו לא רוצים לקבל 90 אחוז דיוק על תמונה שהיא כולה שחורה.

► לכן בעזרת דייס סקור הגענו לתוצאות יותר אמיתיות כי הוא משווה כל פיקסל ואיך שהוא צריך להיות ואיך הוא יצא מהמודל.

► התוצאות שקיבלנו הינם:

DICE: 51% ►

ACCURACY: 97% ►



ניסויים בדרך

- ▶ תחילה השתמשנו בקוד של סטודנט משנה שעברה אשר כתב את הרשת ב TensorFlow וניסינו להעביר את המודל ל PyTorch לאחר עבודה רבה בניסיון להמיר את המודל הבאנו שכדי להצליח אנו נצטרך להבנות את המודל בעצמנו מהתחלה.
- ▶ תמונות D3 MRI בשל חוסר בדאטה מבית החולים ניסינו למצוא באינטרנט תמונות בפורמט dcm לאחר נסיונות רבים ומעבר על הרבה דאטה לא מצאנו בסיס נתונים שתואם לצרכים שלנו ומתוייג כראוי לכן המשכנו עם תמונות הרנטגן.

תוצאות

